

Use Deep Learning in PIV

Zhichao Zhang

01.05.2023

目录

1	前人珠玉	2
1.1	光流法的开始	2

1.2 在光流法中使用深度学习的一篇综述文章	3
1.3 使用深度神经网络的非监督学习	3
1.4 一种很厉害的人工数据生成方法?	5
1.5 Flownet: the father of velocity field estimate	7

1 前人珠玉

1.1 光流法的开始

光流是在一个图像中亮度pattern的移动的近似速度的分布。光流能从物体和观测者的相对移动中得到。因此，光流能够给出关于观测到的物体的空间布置以及其布置的变化率的重要信息。

在不添加额外约束的前提下，光流不能在独立于其相邻点的单个点上计算，因为每个点的速度场有两个方向，而图像在一个点上由于运动而产生的亮度变化只能产生一个约束。

例如，考虑一个pattern中的一块，这一块的亮度只随一个坐标轴而变化。pattern在这个方向上的运动会改变一个某个点的亮度，但在另一个方向上的运动不会改变它的亮度。因此必须添加额外的约束。

1.2 在光流法中使用深度学习的一篇综述文章

Optical Flow Estimation in the Deep Learning Age Junhwa Hur and Stefan Roth

近三十年来，光流法估计领域的研究就一直被Horn和Schunck提出的各种变种影响。他们提出的能量最小化公式包含数据项和空间平滑项。其中数据项鼓励在时间对应像素上的亮度不变，而空间平滑项则使相邻的像素具有相似的运动，以克服光圈问题。

1.3 使用深度神经网络的非监督学习

在文章[1]中，提出了使用卷积神经网络对稠密光学流场进行非监督学习的方法。这篇文章中，首先分析了传统的流场速度分析方法及其优缺点，如果使用交叉相关性，计算量比较小，但是生成的流场是空

间稀疏的，其稀疏程度取决于检测窗口，而且其得到的流场位移信息需要经过后处理。而基于变分的方法，虽然能生成连续的流场速度分布，但其计算量很大，因为这个一个优化问题，需要很多次的迭代来找到最优解。在当时2020年，还没有出现使用非监督学习的方法进行流场速度分析的先例。因为获取带有速度标注信息的流场速度数据集十分困难，如果使用人工数据，则一定会与真实数据存在差别，这个差别会导致当这个方法被泛化到真实数据时，存在一定的误差。

之前有使用监督学习的FlowNetS和FlowNetC[2]，都在稠密光学场图像速度分析中取得了很好的成绩，而其改进版FlowNet2[3]更是干到了SOTA的成绩，并且之后也提出了更为轻量化的LiteFlowNet，其在保持分析进度不变的前提下，减少了模型参数，有望使用到实时系统之中。

他还有提到在这篇文章[4]中，提出了使用非监督学习进行流场速度分析，并提出了photometric loss和smoothness loss，他的文章最后使用的loss正是以此为基础，加入了一个consistency loss，用于反向流场的连续性约束。

这篇文章中使用的正向流场与反向流场的思想来源于[3]这篇文章。

他在文中提到，这些网络的问题有二，第一是使用了大量的标注数据，这些数据的标注工作十分繁

重，不易获得，或者使用了人工数据，与真实数据存在差别，可以预见其模型的泛化能力会受到影响。二是这些网络只能用于刚体或局部刚体(rigid or quasi-rigid)。

他使用的是来自[5]生成的人工数据。这里一个很奇怪的点是，明明他之前批评别人使用人工数据，容易造成模型在真实数据中泛化能力差的问题，他自己又只使用人工数据。难道[5]生成人工数据的方法很厉害？这个待研究。

目前的计划是复现这个实验，研究其使用的数据集，以及将其结果与davis的piv方法作比较。

1.4 一种很厉害的人工数据生成方法？

现在是关于这篇文章[6]的，读这篇文章的动力是，前一篇文章中提到，他使用的数据集是来自于这篇文章的，而且他虽然自己批评了别人使用人工数据会导致泛化性不好，但是自己仍然是使用了这篇文章生成的人工数据，所以想看看这种传说中的数据生成方法到底有多厉害。

这篇文章宣称自己是第一个在piv领域全局使用cnn的模型。

文章在intro的部分花了很大的篇幅介绍piv技术，以及卷积的概念。说piv，无论是基于交叉相关性的还是关于变分的，虽然现在应用很广，而且可靠性很高，但是要么没法生成稠密速度场，要么计算量比较大。基于dnn的虽然在训练的时候计算比较大，但是做inference的时候就很快，有在实时系统使用的潜力。

这篇文章的两个主要贡献：

一是改进了FlowNetS，全局使用了卷积层。具体是在expanding part中，去掉了计算量很大且不准的插值法，以反向卷积代替，并对应的调整了不同层的损失函数权重，且对速度和图像数据都进行了归一化。

二是提出了一种人工piv数据生成的办法。根据一个matlab中的库PIVlab中的工具particle image generator，单个粒子的图像可以用两个方向的高斯分布建模。而后，生成了不同类型的速度场。这里有个问题，就是这些速度场的图像他是怎么生成的？这个问题之后还是要想办法搞清楚。与此同时，他还给出了一些现成的piv图像数据集，之后可以考虑使用这些数据集来训练。将生成的粒子放入速度场，假设粒子没有质量，能够完全跟随速度场，就可以根据粒子所在的位置预测出粒子在下一个时刻的位置，由此得到

两个连续的粒子分布图像，与使用的速度场一起，作为模型的input。还做了一些data augmentation

1.5 Flownet: the father of velocity field estimate

a simple choice is to stack both input images together and feed the through a rather generic network: FlowNetSimple. But we can never be sure that a local gradient descent can get the network to this point. Therefore, hand-design a architecture which is less generic

create two separate, yet identical processing streams for the two images and to combine them at a later stage.

correlation layer: combine feature maps from two image

参考文献

- [1] Mingrui Zhang and Matthew D. Piggott. Unsupervised learning of particle image velocimetry.
- [2] Philipp Fischer, Alexey Dosovitskiy, Eddy Ilg, Philip Häusser, Caner Hazırbaş, Vladimir Golkov, Patrick van der Smagt, Daniel Cremers, and Thomas Brox. FlowNet: Learning optical flow with convolutional networks.
- [3] Simon Meister, Junhwa Hur, and Stefan Roth. UnFlow: Unsupervised learning of optical flow with a bidirectional census loss.
- [4] Jason J. Yu, Adam W. Harley, and Konstantinos G. Derpanis. Back to basics: Unsupervised learning of optical flow via brightness constancy and motion smoothness.
- [5] Shengze Cai, Zhicheng Wang, Frederik Fuest, Young-Jin Jeon, Callum Gray, and George Em Karniadakis. Flow over an espresso cup: Inferring 3d velocity and pressure fields from tomographic background oriented schlieren videos via physics-informed neural networks. 915:A102.

-
- [6] Shengze Cai, Shichao Zhou, Chao Xu, and Qi Gao. Dense motion estimation of particle images via a convolutional neural network. 60(4):73.