

Use Deep Learning in PIV

Zhichao Zhang

01.05.2023

目录

1	前人珠玉	2
1.1	使用深度神经网络的非监督学习	2

1.2 一种很厉害的人工数据生成方法?	4
-------------------------------	---

1 前人珠玉

1.1 使用深度神经网络的非监督学习

在文章[1]中, 提出了使用卷积神经网络对稠密光学流场进行非监督学习的方法。这篇文章中, 首先分析了传统的流场速度分析方法及其优缺点, 如果使用交叉相关性, 计算量比较小, 但是生成的流场是空间稀疏的, 其稀疏程度取决于检测窗口, 而且其得到的流场位移信息需要经过后处理。而基于变分的方法, 虽然能生成连续的流场速度分布, 但其计算量很大, 因为这个一个优化问题, 需要很多次的迭代来找到最优解。在当时2020年, 还没有出现使用非监督学习的方法进行流场速度分析的先例。因为获取带有速度标注信息的流场速度数据集十分困难, 如果使用人工数据, 则一定会与真实数据存在差别, 这个差别会导致当这个方法被泛化到真实数据时, 存在一定的误差。

之前有使用监督学习的FlowNetS和FlowNetC[2], 都在稠密光学场图像速度分析中取得了很好的成

绩，而其改进版FlowNet2[3]更是干到了SOTA的成绩，并且之后也提出了更为轻量化的LiteFlowNet，其在保持分析进度不变的前提下，减少了模型参数，有望使用到实时系统之中。

他还有提到在这篇文章[4]中，提出了使用非监督学习进行流场速度分析，并提出了photometric loss和smoothness loss，他的文章最后使用的loss正是以此为基础，加入了一个consistency loss，用于反向流场的连续性约束。

这篇文章中使用的正向流场与反向流场的思想来源于[3]这篇文章。

他在文中提到，这些网络的问题有二，第一是使用了大量的标注数据，这些数据的标注工作十分繁重，不易获得，或者使用了人工数据，与真实数据存在差别，可以预见其模型的泛化能力会受到影响。二是这些网络只能用于刚体或局部刚体(rigid or quasi-rigid)。

他使用的是来自[5]生成的人工数据。这里一个很奇怪的点是，明明他之前批评别人使用人工数据，容易造成模型在真实数据中泛化能力差的问题，他自己又只使用人工数据。难道[5]生成人工数据的方法很厉害？这个待研究。

目前的计划是复现这个实验，研究其使用的数据集，以及将其结果与davis的piv方法作比较。

1.2 一种很厉害的人工数据生成方法？

现在是关于这篇文章[6]的，读这篇文章的动力是，前一篇文章中提到，他使用的数据集是来自于这篇文章的，而且他虽然自己批评了别人使用人工数据会导致泛化性不好，但是自己仍然是使用了这篇文章生成的人工数据，所以想看看这种传说中的数据生成方法到底有多厉害。

这篇文章宣称自己是第一个在piv领域全局使用cnn的模型。

文章在intro的部分花了很大的篇幅介绍piv技术，以及卷积的概念。说piv，无论是基于交叉相关性的还是关于变分的，虽然现在应用很广，而且可靠性很高，但是要么没法生成稠密速度场，要么计算量比较大。基于dnn的虽然在训练的时候计算比较大，但是做inference的时候就很快，有在实时系统使用的潜力。

这篇文章的两个主要贡献：

一是改进了FlowNetS，全局使用了卷积层。具体是在expanding part中，去掉了计算量很大且不准的插值法，以反向卷积代替，并对应的调整了不同层的损失函数权重，且对速度和图像数据都进行了归一化。

二是提出了一种人工piv数据生成的办法。根据一个matlab中的库PIVlab中的工具particle image generator，单个粒子的图像可以用两个方向的高斯分布建模。而后，生成了不同类型的速度场。这里有个问题，就是这些速度场的图像他是怎么生成的？这个问题之后还是要想办法搞清楚。与此同时，他还给出了一些现成的piv图像数据集，之后可以考虑使用这些数据集来训练。将生成的粒子放入速度场，假设粒子没有质量，能够完全跟随速度场，就可以根据粒子所在的位置预测出粒子在下一个时刻的位置，由此得到两个连续的粒子分布图像，与使用的速度场一起，作为模型的input。还做了一些data augmentation

参考文献

- [1] Mingrui Zhang and Matthew D. Piggott. Unsupervised learning of particle image velocimetry.
- [2] Philipp Fischer, Alexey Dosovitskiy, Eddy Ilg, Philip Häusser, Caner Hazırbaş, Vladimir Golkov, Patrick van der Smagt, Daniel Cremers, and Thomas Brox. FlowNet: Learning optical flow with convolutional networks.

-
- [3] Simon Meister, Junhwa Hur, and Stefan Roth. UnFlow: Unsupervised learning of optical flow with a bidirectional census loss.
 - [4] Jason J. Yu, Adam W. Harley, and Konstantinos G. Derpanis. Back to basics: Unsupervised learning of optical flow via brightness constancy and motion smoothness.
 - [5] Shengze Cai, Zhicheng Wang, Frederik Fuest, Young-Jin Jeon, Callum Gray, and George Em Karniadakis. Flow over an espresso cup: Inferring 3d velocity and pressure fields from tomographic background oriented schlieren videos via physics-informed neural networks. 915:A102.
 - [6] Shengze Cai, Shichao Zhou, Chao Xu, and Qi Gao. Dense motion estimation of particle images via a convolutional neural network. 60(4):73.